

Graph Mining – Paper Implementation Report

Pooya Hatami - 4031334011

2025-07-16

مقدمه

این گزارش پیاده‌سازی مربوط به مقاله *An Inductive Reasoning Model based on Interpretable Logical Rules over temporal knowledge graph* است که هدف اصلی آن، پیش‌بینی رویدادهای آینده در گراف‌های دانش زمانی با استفاده از ترکیب روش‌های مبتنی بر جاسازی^۱ و روش‌های مبتنی بر قوانین منطقی^۲ می‌باشد.

مجموعه داده

در این مقاله از سه مجموعه داده استفاده شده که بیانگر رخدادهای سیاسی بین‌المللی در یک بازه زمانی می‌باشند و از تعدادی چهارتایی به شکل (موجودیت اول، رابطه، موجودیت دوم، زمان) تشکیل شده‌اند. توجه شود که زمان به صورت نسبی می‌باشد به این صورت که ۱- بیانگر وقوع رخداد در روز اول بازه زمانی مورد بررسی و ۳۶۵- بیانگر وقوع رخداد در روز ۳۶۵ام می‌باشد.

مجموعه داده	تعداد موجودیت	تعداد روابط	بازه زمانی
ICEWS14	۷۱۲۸	۲۳۰	سال ۲۰۱۴ - ۳۶۵ روز
ICEWS0515	۱۰۴۸۸	۲۵۱	سال ۲۰۰۵ تا ۲۰۱۵ - ۴۰۱۵ روز
ICEWS18	۲۳۰۳۳	۲۵۶	سال ۲۰۱۸ - ۳۰۳ روز

جدول ۱: مقایسه مجموعه داده‌های مورد استفاده

به عنوان مثال یک نمونه داده از این مجموعه داده‌ها به صورت (Barack Obama, Meet, Angela Merkel, 15) می‌باشد که بیانگر ملاقات باراک اوباما با آنگلا مرکل در روز پانزدهم بازه زمانی مورد بررسی است.

روش‌شناسی

هدف اصلی این پژوهش، پیش‌بینی موجودیت مقصد^۳ در گراف‌های دانش زمانی است. به عنوان مثال برای پرسش (آمریکا، تجارت، ؟، ۲۰۰) هدف تشخیص این است که آمریکا در روز دویستم با کدام کشور تجارت خواهد کرد. همچنین این مدل دارای تفسیرپذیری محدودی بوده و می‌تواند مسیری که برای استنتاج موجودیت مقصد به کار برده را بازگو کند.

مدل پیشنهادی شامل سه مرحله اصلی است:

انتخاب موجودیت‌های نامزد

به جای بررسی تمامی موجودیت‌ها (که در ICEWS18 بیش از ۲۳ هزار موجودیت وجود دارد) برای پیش‌بینی موجودیت مقصد، مدل تنها موجودیت‌هایی را در نظر می‌گیرد که در فاصله k-گام^۴ از موجودیت مبدا قابل دسترسی هستند. برای مثال اگر آمریکا در گذشته با چین همکاری کرده و چین با

^۱Embedding

^۲Logical Rules

^۳Tail Entity

^۴k-hop

آلمان صادرات داشته، آنگاه آلمان نیز علاوه بر چین یک نامزد مناسب برای تجارت با آمریکا محسوب می‌شود.

استخراج قوانین منطقی از مسیرهای تاریخی

برای هر جفت (موجودیت مبدأ، موجودیت نامزد)، مسیرهای تاریخی روابط استخراج می‌شود. به عنوان مثال:

- مسیر ۱: آمریکا → [همکاری] → چین (روز ۲۰۰)
- مسیر ۲: آمریکا → [همکاری] → چین → [صادرات] → آلمان (روز ۱۷۰)

این مسیرها وارد شبکه واحد بازگشتی دروازه‌ای^۵ می‌شوند که دنباله روابط را پردازش کرده و جاسازی مسیر تولید می‌کند. سپس با محاسبه شباهت کسینوسی بین جاسازی مسیر و رابطه هدف (تجارت)، امتیاز قانون محاسبه می‌شود.

محاسبه ترجیحات تعاملی موجودیت‌ها

علاوه بر قوانین منطقی، تاریخچه تعاملات مستقیم بین دو موجودیت نیز در نظر گرفته می‌شود. اگر آمریکا و چین اخیراً تعاملات اقتصادی متعددی داشته‌اند، احتمال تجارت آینده بین آن‌ها افزایش می‌یابد.

امتیازدهی نهایی

امتیاز نهایی هر موجودیت نامزد از ترکیب دو عامل محاسبه می‌شود:

$$\text{score}(s, r, o, t) = \max(\text{historical-path score}) + \cos(\text{entity correlation, relation})$$

موجودیتی که بالاترین امتیاز را کسب کند، به عنوان پاسخ نهایی انتخاب می‌شود.

شرح کد

```

1 |— data
2 |   └─ ICEWS14_forecasting
3 |       └─ data.txt
4 |       └─ entity2id.txt
5 |       └─ graph_preprocess_test.pk
6 |       └─ graph_preprocess_train.pk
7 |       └─ graph_preprocess_valid.pk
8 |       └─ quads_neg.pk
9 |       └─ quads_neg_test.pk
10 |      └─ quads_select.pk
11 |      └─ quads_select_test.pk
12 |      └─ relation2id.txt
13 |      └─ split.txt
14 |      └─ stat.txt
15 |      └─ test.txt
16 |      └─ train.txt
17 |      └─ valid.txt
18 |— inference.ipynb
19
```

^۵Gated Recurrent Unit

```

20 |— main_pre.py
21 |— pyHGT
22 |   |— __init__.py
23 |   |— data.py
24 |   |— model.py
25 |— dataprocess.py
26 |— results
27 |   |— bestmodel
28 |       |— ICEWS14_forecasting
29 |           |— his_len_13
30 |               |— test_evaluation.json
31 |               |— trained99.pth

```

در بالا ساختار مهمترین بخش‌های کد آمده که در ادامه بررسی می‌شوند:

فایل پردازش داده (dataprocess.py)

این فایل وظیفه پیش‌پردازش داده‌های خام و تبدیل آن‌ها به فرمت قابل استفاده برای مدل را بر عهده دارد. پارامترهای اصلی این فایل عبارت‌اند از:

- data: مسیر پوشه داده‌های خام
- dataset: نام مجموعه داده (به طور مثال ICEWS14)
- his_len: طول تاریخچه مورد بررسی (۱۳ برای ICEWS14)
- ratio: نسبت نمونه‌های منفی به مثبت (۱)
- k: حداکثر طول مسیرهای استخراج‌شده (۳)
- state: حالت اجرا ('train' یا 'test')

فرآیند پردازش داده

فرآیند پردازش داده شامل مراحل زیر است:

۱. **اضافه کردن روابط عکس:** به ازای هر رابطه از مبدا به مقصد، یک رابطه معکوس از مقصد به مبدا اضافه می‌شود
۲. **ساخت گراف تاریخی:** برای هر زمان t ، گرافی از تمامی رویدادهای قبل از آن زمان ساخته می‌شود
۳. **استخراج زیرگراف:** برای هر چهارتایی، زیرگرافی شامل موجودیت مبدا و تمامی موجودیت‌های نامزد ساخته می‌شود
۴. **استخراج مسیرها:** با استفاده از الگوریتم پیاده‌روی تصادفی^{*} مسیرهای بین موجودیت مبدا و نامزدها تا طول k استخراج می‌شود
۵. **تولید نمونه‌های منفی:** برای هر چهارتایی مثبت، تعدادی چهارتایی منفی با جایگزینی موجودیت مقصد تولید می‌شود

فایل اصلی آموزش (main_pre.py)

این فایل هسته اصلی فرآیند آموزش مدل است و وظیفه مدیریت کل چرخه آموزش، از بارگذاری داده تا ذخیره مدل نهایی و ارزیابی مدل روی داده‌های تست را بر عهده دارد. پارامترهای اصلی این فایل عبارت‌اند از:

^{*}Random Walk

- epochs_conv: تعداد دوره‌های آموزش (۱۰۰)
- lr: نرخ یادگیری (۰.۰۰۱)
- weight_decay_conv: ضریب تنظیم‌سازی (۰.۰۰۰۱)
- embedding_size: ابعاد جاسازی روابط (۲۰۰)
- device_type: نوع پردازنده ('cpu' یا 'cuda')

نوت‌بوک استنتاج (inference.ipynb)

این نوت‌بوک جوپیتر وظیفه ارزیابی مدل آموزش‌دیده و تولید پیش‌بینی‌ها برای داده‌های تست را بر عهده دارد. بر خلاف فایل آموزش که بر روی تولید مدل متمرکز است، این نوت‌بوک برای تحلیل نتایج و نمایش عملکرد طراحی شده است.

مراحل اصلی استنتاج

۱. **بارگذاری مدل آموزش‌دیده:** خواندن وزن‌های ذخیره‌شده از فایل trained99.pth و بازگردانی حالت مدل
۲. **آماده‌سازی داده‌های تست:** بارگذاری فایل‌های پیش‌پردازش‌شده مخصوص تست
۳. **اجرای استنتاج:** پردازش هر پرسش تست و تولید رتبه‌بندی موجودیت‌های نامزد
۴. **تحلیل نتایج:** نمایش نمونه‌هایی از پیش‌بینی‌های مدل با جزئیات

فرآیند رتبه‌بندی نامزدها

برای هر پرسش تست مانند (کنفرانس احزاب سیاسی نیجریه، درخواست، ؟، t):

۱. **استخراج نامزدها:** تمامی موجودیت‌های موجود در زیرگراف مربوطه به عنوان نامزد در نظر گرفته می‌شود
۲. **محاسبه امتیاز قوانین:** برای هر نامزد، بهترین مسیر تاریخی شناسایی شده و شباهت آن با رابطه هدف محاسبه می‌شود
۳. **محاسبه امتیاز تعاملی:** ترجیحات تعاملی تاریخی بین موجودیت مبدا و هر نامزد ارزیابی می‌شود
۴. **ترکیب امتیازها:** امتیاز نهایی از جمع دو امتیاز بالا محاسبه می‌شود
۵. **مرتب‌سازی:** نامزدها بر اساس امتیاز نهایی به صورت نزولی مرتب می‌شود
۶. **تفسیرپذیری:** برای هر پیش‌بینی، مسیر منطقی استفاده‌شده و دلیل انتخاب آن موجودیت به صورت قابل فهم نمایش داده می‌شود، به طوری که کاربر می‌تواند دریابد چرا مدل معتقد است آن موجودیت خاص پاسخ صحیح است

نتایج

کد ارائه شده توسط نویسندگان مقاله ناقص بوده و قابل اجرا نبود. برای پیاده سازی کامل، تغییرات قابل توجهی مطابق با شرح مقاله اعمال شد. به دلیل محدودیت های محاسباتی و حجم بالای داده ها، تنها مجموعه داده ICEWS14 مورد بررسی قرار گرفت.

تغییرات اعمال شده

کاهش زمانی در ماژول همبستگی موجودیت

در اولین گام برای بهبود عملکرد ماژول همبستگی موجودیت، مکانیزم کاهش زمانی^۶ اضافه شد. این مکانیزم وزن بیشتری به روابط اخیر نسبت به روابط قدیمی تر اختصاص می داد. فرمول اصلاح شده به صورت زیر بود:

$$\text{Entity Correlation Module}(s, o) = \sum_i w_i \times \text{rule}_i$$

که در آن $w_i = e^{-\lambda \times \Delta t_i}$ و λ ضریب کاهش زمانی است.

با این حال، نتایج آزمایش ها نشان داد که این تغییر منجر به کاهش عملکرد شده است و در پیاده سازی نهایی اعمال نگردید.

تغییر استراتژی امتیازدهی در آموزش

در پیاده سازی نهایی، تغییر مهمی در نحوه محاسبه امتیاز در مرحله آموزش اعمال شد:

- آموزش: تنها از امتیاز مسیرهای روابط (path score) استفاده شد
- ارزیابی: از ترکیب کامل امتیاز مسیرها و امتیاز تعاملی موجودیت ها استفاده شد

این تغییر منجر به بهبود ۲ درصدی در عملکرد کلی مدل شد.

گزارش عملکرد مدل

در این بخش نتایج پیاده سازی انجام شده با نتایج گزارش شده در مقاله اصلی مقایسه می شود. هر دو آزمایش بر روی مجموعه داده ICEWS14 انجام شده است.

مقدار	معیار	مقدار	معیار
۰.۵۲۴۲	MRR	۰.۵۴۹۷	MRR
۰.۳۸۲۳	Hits_1	۰.۴۱۵۱	Hits_1
۰.۶۰۴۲	Hits_3	۰.۶۳۱۷	Hits_3
۰.۸۰۴۳	Hits_10	۰.۸۰۰۹	Hits_10

جدول ۲: نتایج مقاله اصلی

جدول ۳: پیاده سازی انجام شده

این معیارها عملکرد مدل در رتبه بندی موجودیت های صحیح را نشان می دهند. MRR میانگین رتبه معکوس موجودیت های صحیح، Hits_1 درصد پرسش هایی که موجودیت صحیح در رتبه اول قرار گرفته، Hits_3 و Hits_10 به ترتیب درصد پرسش هایی که موجودیت صحیح در سه و ده رتبه اول قرار گرفته اند.

^۶Time Decaying

اجرای مدل

اجرای مدل هم از طریق پوشه حاوی کد و هم از طریق اجرای آخرین نسخه دفترچه jupyter (inference.ipynb) میسر است که در ادامه توضیحات بیشتر ارائه می‌شود.

**اجرای آخرین نسخه دفترچه jupyter
(inference.ipynb) از طریق colab**

[Open in Google Colab](#)

لینک ریپازیتوری گیت‌هاب

[Open in Github](#)

تحلیل نمونه‌های استنتاج (analyze_inference_samples)

تابع analyze_inference_samples در فایل inference.py وظیفه تحلیل تفسیرپذیری مدل آموزش‌دیده را بر عهده دارد. این تابع با دریافت سه پارامتر time_samples (تعداد نقاط زمانی)، relation_samples (تعداد روابط) و quad_per_relation_samples (تعداد پرسش برای هر رابطه)، به صورت تصادفی زیرمجموعه‌ای از داده‌های تست را انتخاب کرده و فرآیند استدلال مدل را برای هر پیش‌بینی به تفصیل نمایش می‌دهد. برای هر پرسش نمونه، این تابع ده موجودیت برتر پیش‌بینی‌شده همراه با امتیازات مسیر منطقی و تعاملات تاریخی آن‌ها را ارائه می‌کند، به طوری که می‌توان مسیر استدلال مدل و دلایل انتخاب هر موجودیت را درک کرد. نمونه‌ای از خروجی این تابع در شکل زیر آورده شده است. در این مثال، مدل برای پرسش «آژانس مبارزه با مواد مخدر فیلیپین (Pdea) در زمان ۳۴۸ کدام موجودیت را دستگیر خواهد کرد؟» به درستی موجودیت «مجرم فیلیپین» را در رتبه اول پیش‌بینی کرده است. مدل این نتیجه را با امتیاز ۰.۹۸۸۲ و بر اساس مسیر منطقی ReverseOf(Praise_or_endorse) به دست آورده است.

برای درک این مسیر منطقی، باید توضیح دهیم که ReverseOf(Praise_or_endorse) به معنای استفاده از جهت معکوس یک رابطه تاریخی است. این بدان معناست که در گذشته رابطه (زمان_گذشته, Criminal_(Philippines), Praise_or_endorse, Pdea) وجود داشته، یعنی «مجرم فیلیپین» در گذشته از آژانس «Pdea» تمجید یا حمایت کرده است. این الگو می‌تواند نشان‌دهنده رفتارهای مشکوک مانند تلاش برای جلب نظر قبل از افشای فعالیت‌های غیرقانونی توسط مجرم باشد. همچنین امتیاز تعاملی بین موجودیت‌ها در چند فاصله زمانی قبلی (در اینجا ۱۳ روز قبل) برابر با صفر می‌باشد.

```

1 Query: (Pdea, Arrest,_detain,_or_charge_with_legal_action, ?, t_348)
2 Correct Answer: Criminal_(Philippines)
3 Correct Answer Rank: 1
4
5 TOP PREDICTIONS:
6 -----
7 Rank  1: Criminal_(Philippines)          Score: 0.9882 ✓ CORRECT
8         Path: ReverseOf(Praise_or_endorse) Score: 0.9882
9         Interaction: 0.0000
10
11 Rank  2: Military_(Philippines)          Score: 0.4415 x Wrong
12         Path: ReverseOf(Return,_release_person(s)) Score: 0.4415
13         Interaction: 0.0000
14
15 Rank  3: Military_Personnel_-_Special_(Philippines) Score: 0.3758 x
Wrong
16         Path: ReverseOf(Abduct,_hijack,_or_take_hostage) Score: 0.3758
17         Interaction: 0.0000
18
19 Rank  4: City_Mayor_(Philippines)        Score: 0.3188 x Wrong
20         Path: ReverseOf(Provide_humanitarian_aid) Score: 0.3188
21         Interaction: 0.0000
22
23 Rank  5: Director_General_(Philippines)  Score: 0.3174 x Wrong
24         Path: ReverseOf(Engage_in_negotiation) Score: 0.3174
25         Interaction: 0.0000
26
27 Rank  6: Police_(Philippines)            Score: 0.3151 x Wrong
28         Path: ReverseOf(Consult) Score: 0.3151
29         Interaction: 0.0000
30
31 Rank  7: Secret_Agent_(Philippines)      Score: 0.2419 x Wrong
32         Path: ReverseOf(Engage_in_diplomatic_cooperation) Score:
0.2419
33         Interaction: 0.0000
34
35 Rank  8: Philippines                     Score: 0.2390 x Wrong
36         Path: Make_pessimistic_comment Score: 0.2390
37         Interaction: 0.0000

```

اجرای مدل از طریق colab

۱. سلول‌ها به ترتیب و فقط یکبار اجرا شوند

۲. سلول آخر شامل تابع `analyze_inference_samples` را می‌توان چند بار و با پارامترهای مختلف اجرا کرد

در صورت بروز هرگونه خطا گزینه `disconnect and delete runtime` را انتخاب کرده و مجدد تلاش شود.

اجرا از طریق پوشه کد

۱. پروژه از لینک github گزاشته شده دانلود شود
۲. ملزومات پروژه نصب شود
۳. فایل dataprocess.py اجرا شود
۴. برای آموزش و ارزیابی فایل main_pre.py اجرا شود. در صورت عدم نیاز به ارزیابی (گزارش متریک‌ها) و اجرای بسیار سریعتر خط آخر comment شود
۵. حال از طریق دفترچه inference.ipynb می‌توان خروجی را مشاهده و تحلیل کرد

کارهای آینده

- همانطور که از خروجی‌ها مشخص است مدل تقریباً همیشه مسیرهای به طول یک را ترجیح می‌دهد. تشویق مدل به انتخاب مسیرهای پیچیده‌تر میتواند موثر واقع شود.
 - پنجره زمانی (برای در نظر گرفتن تعاملات بین موجودیت‌ها) برای همه موجودیت‌ها یکسان می‌باشد. می‌توان پنجره زمانی را پویا در نظر گرفت.
 - بعضی روابط روی بعضی موجودیت‌ها تعریف نمی‌شوند به طور مثال نمی‌توان یک کشور را دستگیر کرد ولی در این مدل اگر پلیس و کشور در k قدمی یکدیگر باشند، مدل کشور را برای پرسش «پلیس چه کسی را دستگیر کرد» در نظر می‌گیرد. برای حل این مشکل می‌توان از روش‌های برچسب‌گذاری جزء کلام^۸ استفاده کرد.
- بهبودهای پیشنهادی در آینده مورد بررسی قرار خواهند گرفت.